



Транскрипция текстов многоголосного пения


Автоматическое распознавание речи (ASR)

позволяет превратить аудио, где человек говорит, в текст.

А если человек поёт? Получится ли использовать те же языковые модели (Whisper, Qwen и другие) для транскрипции *песенных* текстов?

Эксперименты показывают, что модели для распознавания речи (например, **Qwen3ASR-1.7B**) хорошо справляются с распознаванием текста песен, если в их обучающей выборке были вокальные данные.






Многоголосие создаёт трудности.

В случае если все голоса одновременно поют одинаковый текст, качество распознавания многоголосия падает незначительно.

Однако в ситуации, когда голоса поют **разное** (текст отличается, есть наложения голосов друг на друга), применение моделей ASR напрямую — не самый эффективный метод.

Ниже представлена предлагаемая последовательность применения моделей для транскрипции многоголосного пения.



model_bs_rofor
mer_ep_317_sdr_
12.9755.ckpt

2 голоса:
sepformer-libri2mix
3 голоса:
sepformer-libri3mix

Qwen3ASR-1.7B

Наблюдения

- Указание языка (на этапе распознавания речи) влияет в лучшую сторону
- С увеличением количества голосов падает качество разделения
- Фоновая музыка и артефакты от неё снижают качество разделения
- Манера пения влияет на качество разделения: например, оперное пение распознаётся хуже
- Пение женщин транскрибируется в среднем хуже пения мужчин (мужчины поют чётче)
- Если голоса перекрываются по диапазонам, качество разделения низкое

В целом разделение 2–3 голосов и их транскрипция осуществима (хотя некоторые виды пения вызывают сложности)

Примеры транскрипции можно увидеть здесь:

