

Разработка нейросетевого инструмента для транскрипции текста многоголосного пения

Татьяна Авдеева
руководитель — Э. С. Клышинский

Идея



abba waterloo текст




abba waterloo текст — найти в Яндексе


Идея



Идея




Идея




ASR



Идея




Идея



ASR?



Идея



ASR?

Коротко: да, если голоса
не перекрывают друг друга

Дисклеймер

Все результаты
экспериментов получены
лично автором работы.

папка с аудио



Данные

- Cantoría Dataset
 - 11 песен времён Золотого века
 - профессиональный вокальный квартет
 - есть отдельно каждый голос, все голоса вместе и все голоса вместе с органом
- ...и другие данные, не доступные открыто (оперное пение, рэп, эстрада и др.)



Разные модели (1-голосное пение)

reference	prediction	WER	CER	модель	аудиофрагмент
¿Cómo podéis siendo criatura Señora, parir al que es Criador Pues siendo vos su propia hechura Él os es Padre y superior?	¿Cómo podéis siendo criaturas, señora, parir al que es criador? Pues siendo vos su propia hechura, él os es padre y superior.	4.55%	0.85%	Whisper Large V3	Cantoria_SSS_B_cut_...
¿Cómo podéis siendo criatura Señora, parir al que es Criador Pues siendo vos su propia hechura Él os es Padre y superior?	siendo criatura señor aparir al que es criador pues siendo vos su propia hechura él os es padre y superior	18.18%	11.86%	cohere-transcribe-03-2026	Cantoria_SSS_B_cut_...
¿Cómo podéis siendo criatura Señora, parir al que es Criador Pues siendo vos su propia hechura Él os es Padre y superior?	Cómo podéis siendo criaturas señora parir al que es criador, pues siendo vos su propia hechura él os es padre y superior.	4.55%	0.85%	Qwen3-ASR-1.7B	Cantoria_SSS_B_cut_...

cohere-transcribe-03-2026 сместила с 1-го места **Qwen3-ASR-1.7B** в ASR-бенчмарке HF (mean WER 5.42% vs 5.76%),
однако в распознавании именно пения **Qwen3-ASR-1.7B** лучше



Но что если певцов несколько?


ASR для многоголосия

reference	prediction	WER	CER	голосов	а капелла	аудиофрагмент
¿Cómo podéis siendo criatura Señora, parir al que es Criador Pues siendo vos su propia hechura Él os es Padre y superior?	Cómo podéis siendo criaturas señora parir al que es criador, pues siendo vos su propia hechura él os es padre y superior.	4.55%	0.85%	1	да	Cantoria_SSS_B_cut_...
¿Cómo podéis siendo criatura Señora, parir al que es Criador Pues siendo vos su propia hechura Él os es Padre y superior?	Cómo podéis, siendo criatura, señora, pedir al que es Criador? Pues siendo vos su propia hechura, él os es padre y superior.	4.55%	1.69%	4	да	Cantoria_SSS_Mix_cu...
¿Cómo podéis siendo criatura Señora, parir al que es Criador Pues siendo vos su propia hechura Él os es Padre y superior?	Como podéis, siendo criatura, señora, pedir al que es Criador, pues siendo vos su propia hechura, eres padre y superior.	22.73%	7.63%	4	нет	Cantoria_SSS_MixOrg...

- Если все голоса одновременно поют одно и то же, ASR работает хорошо
- Фоновая музыка может влиять в худшую сторону



А если все поют вразнобой?



ASR для многоголосия


reference	prediction	WER	CER	голосов	а капелла	аудиофрагмент
Corten espadas afiladas, lenguas malas. Corten espadas afiladas, lenguas malas, lenguas malas.	Corten espadas afiladas, lenguas malas. Corten espadas afiladas, lenguas malas, lenguas malas.	0.0%	0.0%	1	да	Cantoria_CEA_T_cut_...
Corten espadas afiladas, lenguas malas. Corten espadas afiladas, lenguas malas, lenguas malas.	Cortes, cortes, filas afiladas, lenguas malas, lenguas malas.	58.33%	41.57%	4	да	Cantoria_CEA_Mix_c...
Corten espadas afiladas, lenguas malas. Corten espadas afiladas, lenguas malas, lenguas malas.	Cordes finas, cordes finas, lenguas malas, lenguas malas. Cordes finas, cordes finas, falas afidadas, lenguas malas, lenguas malas.	100.0%	50.56%	4	нет	Cantoria_CEA_MixOr...

- А если есть наложения и/или голоса поют немного разное, распознавание речи без разделения по голосам работает плохо


A waiter in a black suit is shown from the chest up, holding a silver dome-shaped object (likely a cloche) over a silver plate. The waiter's hands are visible, and the background is white. The text "Предлагаемый метод" is overlaid on the image.

Предлагаемый метод

Pipeline



Pipeline



**model_bs_rofor
mer_ep_317_sdr_
12.9755.ckpt**

**2 voices:
sepformer-libri2mix
3 voices:
sepformer-libri3mix**

Qwen3ASR-1.7B

~~Background music~~ > SS > ASR (2 голоса)

reference	prediction	WER	CER	голосов	а капелла	SSS	after bad SS	аудиофрагмент
Corten espadas afiladas lenguas malas. Corten espadas afiladas lenguas malas, lenguas malas.	Corten espadas afiladas, lenguas malas. Corten espadas afiladas, lenguas malas, lenguas malas.	0.0%	0.0%	2	да	да	нет	mixed_combo_CEA_...
Corten espadas afiladas lenguas malas. Corten espadas afiladas, afiladas lenguas malas, lenguas malas.	Corten espadas afiladas, lenguas malas. Corten espadas afiladas, afiladas, lenguas malas, lenguas malas.	0.0%	0.0%	2	да	да	нет	mixed_combo_CEA_...
Corten espadas afiladas lenguas malas. Corten espadas afiladas lenguas malas, lenguas malas.	Corten espadas afiladas, lenguas malas, lenguas malas. Corten espadas afiladas, afiladas, lenguas malas, lenguas malas.	25.0%	25.84%	2	да	нет	нет	mixed_combo_CEA_...

- Результаты действительно лучше после качественного отделения голосов друг от друга!

~~Background music~~ > SSS > ASR (3 голоса)

reference	prediction	WER	CER	голосов	а капелла	SSS	after bad SS	язык указан	аудиофрагмент
Corten espadas afiladas lenguas malas. Corten espadas afiladas lenguas malas, lenguas malas.	Corte espadas afiladas, lenguas malas. Corte espadas afiladas, afiladas, lenguas malas, lenguas malas.	25.0%	12.36%	3	да	да	нет	нет	mixed_combo_CEA_...
Corten espadas afiladas lenguas malas. Corten espadas afiladas, afiladas lenguas malas, lenguas malas.	Fortunes fadas, afiladas, lenguas malas. Fortunes fadas, afiladas, lenguas malas, lenguas malas.	33.33%	11.24%	3	да	да	нет	нет	mixed_combo_CEA_...
Corten espadas afiladas lenguas malas. Corten espadas afiladas lenguas malas, lenguas malas.	Corten espadas afiladas, lenguas malas. Corten espadas afiladas, lenguas malas, lenguas malas.	0.0%	0.0%	3	да	да	нет	нет	mixed_combo_CEA_...
Corten espadas afiladas lenguas malas. Corten espadas afiladas lenguas malas, lenguas malas.	Corte espadas, cortes peladas, afiladas, lenguas malas, lenguas malas.	50.0%	31.46%	3	да	да	нет	нет	mixed_combo_CEA_...

- Результаты действительно лучше после качественного отделения голосов друг от друга!

~~Background music~~ > SSS > ASR (3 голоса)

reference	prediction	WER	CER	голосов	а капелла	SSS	after bad SS	язык указан	аудиофрагмент
Corten espadas afiladas lenguas malas. Corten espadas afiladas lenguas malas, lenguas malas.	Corte en espadas afiladas, lenguas malas. Corte en espadas afiladas, afiladas, lenguas malas, lenguas malas.	41.67%	14.61%	3	да	да	нет	да	mixed_combo_CEA_...
Corten espadas afiladas lenguas malas. Corten espadas afiladas, afiladas lenguas malas, lenguas malas.	Fortunes faldas afiladas, lenguas malas. Fortunes faldas afiladas, lenguas malas, lenguas malas.	33.33%	13.48%	3	да	да	нет	да	mixed_combo_CEA_...
Corten espadas afiladas lenguas malas. Corten espadas afiladas lenguas malas, lenguas malas.	Corten espadas afiladas, lenguas malas. Corten espadas afiladas, lenguas malas, lenguas malas.	0.0%	0.0%	3	да	да	нет	да	mixed_combo_CEA_...
Corten espadas afiladas lenguas malas. Corten espadas afiladas lenguas malas, lenguas malas.	Corte espadas, corte espadas afiladas, lenguas malas, corte espadas, corte espadas afiladas, lenguas malas, lenguas malas.	50.0%	31.46%	3	да	да	нет	да	mixed_combo_CEA_...

- Результаты действительно лучше после качественного отделения голосов друг от друга!
- Вне зависимости от того, задан язык или нет

~~Background music~~ > SSS > ASR

reference	prediction	WER	CER	голосов	а капелла	SSS	after bad SS	язык указан	аудиофрагмент
Pur ti stringo, pur ti stringo, più non moro	Or destri, corde, corde più non temo.	77.78%	52.38%	2	да, по...	да	да	да	Pur_ti_miro_cut.wav
Pur t'annodo; Più non peno	Guarda la luna più grande.	100.0%	70.83%	2	да, по...	да	да	да	Pur_ti_miro_cut.wav
Pur ti stringo, pur t'annodo; Più non peno, più non moro	pur di stringerlo, più non perdo.	72.73%	50.0%	2	да, по...	нет	нет	да	Pur_ti_miro_cut.wav
Блинов я напеку. Вы пекитесь, блины, пышные, поднимайтесь! А гости за столом собирайтесь.	Блинок я на пеку, выпекайтесь, блины пышные, поднимайтесь, а гости за соус бираетесь.	53.85%	17.07%	2	да, по...	да	?	да	blinis_cut.wav
Блинов я напеку. Вы пекитесь, блины, пышные, поднимайтесь! А гости за столом собирайтесь.	Блинок я на беку выпекись я блины и шлифованийся до гости за столом спирайтесь.	69.23%	28.05%	2	да, по...	да	?	да	blinis_cut.wav
Блинов я напеку. Вы пекитесь, блины, пышные, поднимайтесь! А гости за столом собирайтесь.	Блинок я на пеку, выпекайтесь, блины пышные, поднимайтесь, а гости за стол убирайтесь.	53.85%	10.98%	2	да, по...	нет	нет	да	blinis_cut.wav

- Но не всегда

Наблюдения

- Указание языка влияет в лучшую сторону (очевидно)
- С увеличением количества голосов падает качество разделения
- Фоновая музыка и артефакты от неё снижают качество разделения
- Манера пения влияет на качество разделения: например, оперное пение распознаётся хуже
- Пение женщин транскрибируется в среднем хуже пения мужчин (мужчины поют чётче)
- Если голоса перекрываются по диапазонам, качество разделения низкое

В целом разделение 2–3 голосов и их транскрипция осуществима, если это не оперное пение

Наблюдения (продолжение)

- Если текст слышен нечётко, ASR-модель может галлюцинировать

reference	prediction	WER	CER	голосов	after bad SS	язык указан	аудиофрагмент
Nol dite a chi l'ignora, Godiamo, la tazza, la tazza e il cantico la notte abbella e il riso	La luna mi guida, la luna mi guida. La luna su casa mia, la luna di mezzo ai miei bisogni.	94.74%	71.59%	3	да	да	Libiamo_end.wav
Nol dite a chi l'ignora, Godiamo, la tazza, la tazza e il cantico la notte abbella e il riso	I'll be your beacon in the dark. I'll be your shelter from the storm.	100.0%	76.14%	3	да	нет	Libiamo_end.wav
La vita e' nel tripudio Nol dite a chi l'ignora	La bella mia figlia, la regina mia, così.	90.0%	71.11%	2	да	да	Libiamo_S_T.wav
quando non s'ami ancora e il mio destin così	Quando non sa mi ancora, è il mio destino così.	55.56%	9.3%	2	нет	да	Libiamo_S_T.wav

Перспективы

- Требуются датасеты оперного пения и многоголосного пения вообще (таких мало, а те, что есть, небольшого объёма)
- Можно пробовать шумоподавление на одном или нескольких этапах
- Singing-to-speech-подход вызывает сомнения

Спасибо за внимание!

